

廈門大學


中 期 汇 报

OpenHarmony 向标联合查询中期汇报

汇报人：林正刚

需求点	状态	备注
动态增量混合索引	完成	10k 以内走内存 flat exact KNN，超过阈值后落盘为磁盘图。
查询 10@10 召回率稳定 >98%	完成	
标量等值与范围查询	完成	
联合向量近似查询时延 <10ms	完成	
内存限制 30M 左右	完成	
索引膨胀率不能高于原始向量 1 倍	部分完成	目前 R=116 情况下索引膨胀率略超；也可以使用 R=75，但插入删除会对图质量有比较大的影响。

需求 0：从 0 插入与小规模搜索



实现路径

空索引启动时进入内存 flat 模式；0-10k 向量直接插入内存数组并执行 exact KNN，不训练 PQ、不生成磁盘图。

live count 超过 10k 后，再一次性 materialize 为磁盘图索引。

实验结果




SIFT1M 前 10k 向量实验中，10k 以内全部保持 flat mode。

单查询 peak RSS 最高约 **32.3 MiB**，接近 30MB 要求。


平均搜索延迟最高约 **0.20 ms**，显著低于 10ms 延迟要求；10k 附近 QPS 约 **5k**。

结论：已支持从 0 数据量开始插入，小规模阶段基本满足内存和延迟要求。

根据过滤选择性阈值 τ_m ，在同一个磁盘图索引上选择 prefilter 或 inline-processing ANNS。



τ_m 是 prefilter 和 graph search 的切换边界；它不是固定常数，而是随索引状态重新校准。



标定方式



- 对每个选择性 bucket 校准 L ，只保留满足 recall 目标的点。
- 在这些点上比较 prefilter 与 graph search 的延迟曲线。
- prefilter 随选择性增大而变慢；graph search 反之。
- 两条曲线交点即 τ_m ：左侧走 prefilter，右侧走 graph。
- live count 漂移超过阈值时后台重标定；完成前使用旧 τ_m ，完成后原子切换到新 τ_m 。

需求 1：召回率对比

左图：直接构建 vs 增量插入。分别直接构建 250k、500k、750k、1M 索引，并与从不同初始规模索引插入到相同规模后的索引比较；两类索引在同一个 L 下执行搜索，用于衡量直接构建和增量插入得到的图质量差距。实验中 recall 差距在 0.5% 以内，基本没有影响。

右图：删除 / 重插入后的图质量。先构建 1M 索引，删除 250k 向量得到 750k 索引，再插入 250k 向量回到 1M，对三个索引状态分别运行搜索测试。结果显示选择性超过 50% 后 recall 差异缩小到 1% 以内。


结论：删除和插入操作对图质量影响较小。



需求 2：插入期间前台查询

在初始 1M 索引上插入向量的同时执行前台搜索，测量搜索延迟与 QPS，结果如下图。

结论：在插入线程数小于 4 时，向量插入并不会对前台搜索性能产生显著影响。






需求 3：选择性查询延迟/QPS

在直接构建的 1M 索引上，对 intersect 等值过滤和 range 范围过滤分别校准 route/L，测量单线程 latency 与 QPS；本轮全量结果中所有点均满足 $\text{recall}@10 \geq 98$ 。

结论：启用 io_uring 后，intersect 与 range 全部选择性下单线程延迟均低于 10ms。

Exp4: Direct 1M intersect/range search, selected route and minimum L for $\text{recall}@10 \geq 98\%$





口径

只加载必要文件到内存，完成单个查询的搜索流程并返回结果；不加载 query file、groundtruth 等其他文件。

实测结果

20 个点范围为 **12.39–18.15 MiB**；
intersect 峰值 17.17 MiB，range 峰值 18.15 MiB。

结论：满足 30MB 内存要求。

原始向量空间按 $\text{npoints} * 128 * 4$ 计算；1M 索引膨胀率约为 2.06x，额外索引空间满足 $\text{extra/raw} \leq 1.0$ 。

- 250k: raw 122.07 MiB；其他文件合计 252.20 MiB，其中 disk.index 244.14 MiB, PQ compressed 7.63 MiB, PQ pivots 0.13 MiB, labels.densebit 0.30 MiB。
- 500k: raw 244.14 MiB；其他文件合计 504.27 MiB，其中 disk.index 488.29 MiB, PQ compressed 15.26 MiB, PQ pivots 0.13 MiB, labels.densebit 0.60 MiB。
- 750k: raw 366.21 MiB；其他文件合计 756.34 MiB，其中 disk.index 732.43 MiB, PQ compressed 22.89 MiB, PQ pivots 0.13 MiB, labels.densebit 0.89 MiB。
- 1M: raw 488.28 MiB；其他文件合计 1008.41 MiB，其中 disk.index 976.57 MiB, PQ compressed 30.52 MiB, PQ pivots 0.13 MiB, labels.densebit 1.19 MiB。

THE END

谢谢

