

廈門大學


本科毕业答辩

PipeANN 动态更新实验汇报

答辩人：林正刚

指导教师：沈志荣教授


核心目标：同一个索引同时支持低选择性过滤查询和高选择性近似搜索，并为每个查询选择更合适的执行路径。



框架做的事情

- 查询入口统一，先解析过滤条件并估计选择性。
- prefilter 适合小候选集合：先过滤，再用 PQ/距离计算重排。
- graph search 适合高选择性：避免扫描大候选集合，利用图结构快速逼近近邻。
- route 由 τ_m 控制；L 单独校准，保证 recall 下限。

τ_m 是 prefilter 和 graph search 的切换边界；它不是固定常数，而是随索引状态重新校准。



两类标定时机



- **初始标定：**索引 build 完成后立即执行，得到第一版 τ_m 和 route table。
- **漂移重标定：**插入或删除导致 live vector 数量相对上次标定点漂移超过阈值，例如 10%，重新抽样并重跑校准。
- **更新口径：**标定只决定 route 边界；L 仍按 recall 目标选择。
- **发布方式：**新表原子替换旧表，后续查询使用新 τ_m 。

需求 1：召回率对比

左图：直接构建 vs 增量插入。分别直接构建 250k、500k、750k、1M 索引，并与从不同初始规模索引插入到相同规模后的索引比较；两类索引在同一个 L 下执行搜索，用于衡量直接构建和增量插入得到的图质量差距。实验中 recall 差距在 0.5% 以内，基本没有影响。

右图：删除 / 重插入后的图质量。先构建 1M 索引，删除 250k 向量得到 750k 索引，再插入 250k 向量回到 1M，对三个索引状态分别运行搜索测试。结果显示选择性超过 50% 后 recall 差异缩小到 1% 以内。


结论：删除和插入操作对图质量影响较小。



需求 2：插入期间前台查询

在初始 1M 索引上插入向量的同时执行前台搜索，测量搜索延迟与 QPS，结果如下图。

结论：在插入线程数小于 4 时，向量插入并不会对前台搜索性能产生显著影响。





需求 3: 选择性查询延迟/QPS


在直接构建的 1M 索引上, 对 intersect 等值过滤和 range 范围过滤分别校准 route/L, 测量单线程 latency 与 QPS; 本轮全量结果中所有点均满足 $\text{recall}@10 \geq 98$ 。

结论: 启用 io_uring 后, intersect 与 range 全部选择性下单线程延迟均低于 10ms。

Exp4: Direct 1M intersect/range search, selected route and minimum L for $\text{recall}@10 \geq 98\%$



需求 4：单查询 RSS



口径

干净单查询进程总内存；query vector 和过滤 label 通过命令行传入，不加载 query file、groundtruth 或 query spat。

实测结果

20 个点范围为 **12.39–18.15 MiB**；intersect 峰值 17.17 MiB，range 峰值 18.15 MiB。

结论：PQ code 改为 mmap 后，单查询进程 RSS 已低于 30MB 目标。

原始向量空间按 $\text{npoints} * 128 * 4$ 计算; 额外索引空间均满足 $\text{extra/raw} \leq 1.0$ 。

- 250k: raw 122.07 MiB; 其他文件合计 252.20 MiB, 其中 disk.index 244.14 MiB, PQ compressed 7.63 MiB, PQ pivots 0.13 MiB, labels.densebit 0.30 MiB。
- 500k: raw 244.14 MiB; 其他文件合计 504.27 MiB, 其中 disk.index 488.29 MiB, PQ compressed 15.26 MiB, PQ pivots 0.13 MiB, labels.densebit 0.60 MiB。
- 750k: raw 366.21 MiB; 其他文件合计 756.34 MiB, 其中 disk.index 732.43 MiB, PQ compressed 22.89 MiB, PQ pivots 0.13 MiB, labels.densebit 0.89 MiB。
- 1M: raw 488.28 MiB; 其他文件合计 1008.41 MiB, 其中 disk.index 976.57 MiB, PQ compressed 30.52 MiB, PQ pivots 0.13 MiB, labels.densebit 1.19 MiB。

THE END

谢谢

