

廈門大學

中 期 汇 报

OpenHarmony 向标联合查询中期汇报

汇报人：林正刚

年度课题-挑战方向3：向标联合查询性能优化




技术背景

端侧向量数据库（比如Ark Data自研数据库）通过标量向量数据的统一管理和联合查询，支撑：小艺记忆语义内容查询、小艺搜索本地数字资产语义问答。
为了在大数据集上快速查询，建立向量索引与标量索引，在联合查询场景下维护两套索引，若选择不好的执行计划，查询时延会大幅上升，对DB带来较大压力。

技术挑战

1. 端侧数据库考虑资源功耗问题没有统计信息，无法通过代价计算选择生成执行计划。
2. 构建轻量级混合索引，低底噪、低功耗、低时延查询。

当前结果



技术诉求

实现低功耗稳定低时延的向量标量联合查询。

1. 客观效率方面：百万128维向量与标量数据集下标量条件等值或者范围查询联合向量近似查询中，标量条件命中数量多少不影响时延召回率，10@10召回率>98%；
2. 主观感受方面：在对表中数据查询，对查询条件包含标量等值或这个范围查询并包含向量近似查询召回率与性能稳定，不会由于数据分布的问题导致部分查询出现劣化。

分解目标

动态增量混合索引：端侧数据是会不断增加更新，索引应可以从0数据量开始构建，增量更新数据不影响召回率。



情景举例：在端侧用户创建表和索引构建后用户插入大量数据，查询数据满足标量条件以及最近似的查询向量top10，低延时稳定查出结果。

考量点：(1)数据不断增删改，查询10@10召回率稳定>98%；(2)索引能够支持标量等值与范围查询，联合向量近似查询时延<10ms；(3)页缓存内存限制10M左右；(4)索引膨胀率不能高于原始向量1倍。(5)基于mate60进行验证。


OpenAtom OpenHarmony

需求点	状态	备注
动态增量混合索引	完成	10k 以内走纯内存精确近邻搜索，超过阈值后落盘为磁盘图。
查询 10@10 召回率稳定 >98%	完成	
标量等值与范围查询	完成	
联合向量近似查询时延 <10ms	完成	
内存限制 30M 左右	完成	
索引膨胀率不能高于原始向量 1 倍	部分完成	目前 R=116 情况下索引膨胀率略超；也可以使用 R=75，但插入删除会对图质量有比较大的影响。

根据过滤选择性阈值 τ_m ，在同一个磁盘图索引上选择 prefilter 或 inline-processing ANNS。



τ_m 用来判断过滤后候选集是否足够小：小就先过滤再算距离，大就直接在图上边搜边过滤。



曲线含义

- 先过滤：选择性越高，符合条件的向量越多，需要计算 PQ 距离的候选越多，延迟上升。
- 图搜索：选择性越高，图上遇到的有效（符合过滤条件）的点越多，更容易凑齐 TopK，搜索范围缩小。

标定方式


- 选择一系列过滤选择性点，例如 1%、5%、10%、25%、50%、100%。
- 对以上所有选择性，运行轻量级查询，分别测出两条路径上满足目标召回率的最小延迟。
- 两条延迟曲线的交点即为 τ_m 的值。
- 若插入/删除向量使索引规模变化达到一定值，则在前台查询负载较低时重新运行上述流程，更新 τ_m 。

需求 0：从 0 插入与阈值前搜索

从 0 数据量向索引中插入向量时，进入纯内存模式；0–10k 向量直接插入内存数组，并执行精确近邻搜索。该阶段不训练 PQ、不生成磁盘图；索引中向量数超过 10k 后，再一次性落盘为磁盘图索引。

SIFT1M 前 10k 向量实验中，10k 以内全部保持纯内存模式；单查询峰值 RSS 最高约 **32.3 MiB**，接近 30MB 要求；平均搜索延迟最高约 **0.20 ms**，显著低于 10ms 延迟要求，10k 附近 QPS 约 **5k**。



结论：已支持从 0 数据量开始插入；落盘前延迟满足要求，内存占用与 30MB 目标基本一致。



左图：直接构建 vs 增量插入。分别直接构建 250k、500k、750k、1M 索引，并与从不同初始规模索引插入到相同规模后的索引比较；两类索引在同一个 L 下执行搜索，用于衡量直接构建和增量插入得到的图质量差距。实验中召回率差距在 0.5% 以内，基本没有影响。

右图：删除 / 重插入后的图质量。先构建 1M 索引，删除 250k 向量得到 750k 索引，再插入 250k 向量回到 1M，对三个索引状态分别运行搜索测试。结果显示选择性超过 50% 后 recall 差异缩小到 1% 以内。

结论：删除和插入操作对图质量影响较小。





需求 2：插入期间前台查询

在初始 1M 索引上插入向量的同时执行前台搜索，测量搜索延迟与 QPS，结果如下图。

结论：在插入线程数小于 4 时，向量插入并不会对前台搜索性能产生显著影响。


Exp3: foreground search during insertion



需求 3：选择性查询延迟/QPS

在直接构建的 1M 索引上，对等值查询和范围查询分别校准查询路径与 L ，测量单线程延迟与 QPS；本轮全量结果中所有点均满足 $\text{recall}@10 \geq 98$ 。


结论：等值查询与范围查询在全部选择性下，单线程延迟均低于 10ms。




需求 3: 1-16 线程延迟分位数

在 r116/PQ32 直接构建的 1M 索引上, 对等值查询和范围查询覆盖全部 10 个选择性, 并扫描前台查询线程数 1-16; 图中每个点取对应线程数下所有选择性中的最坏延迟。

结论: 全部 320 个组合 $\text{recall}@10 \geq 98$, 平均延迟均低于 10ms。





测量方法

只加载必要文件到内存，完成单个查询的搜索流程并返回结果；不加载 query file、groundtruth 等其他文件。

实测结果

20 个点范围为 **12.39–18.15 MiB**；
等值查询峰值 17.17 MiB，范围查询峰值 18.15 MiB。

结论：满足 30MB 内存要求。

R=116 下，额外索引文件主要来自磁盘图；1M 数据规模下额外空间约为原始向量的 2.06 倍。

规模	原始向量	磁盘图	PQ 压缩向量	PQ 码本	标签位图	额外合计	额外/原始
250k	122.07	244.14	7.63	0.13	0.30	252.20	2.07x
500k	244.14	488.29	15.26	0.13	0.60	504.27	2.07x
750k	366.21	732.43	22.89	0.13	0.89	756.34	2.07x
1M	488.28	976.57	30.52	0.13	1.19	1008.41	2.06x

单位：MiB；额外/原始为额外合计与原始向量的比值。

THE END

谢谢

