

廈門大學

中期汇报

OpenHarmony 向标联合查询中期汇报

汇报人：林正刚

年度课题-挑战方向3：向标联合查询性能优化




技术背景

端侧向量数据库（比如Ark Data自研数据库）通过标量向量数据的统一管理和联合查询，支撑：小艺记忆语义内容查询、小艺搜索本地数字资产语义问答。
为了在大数据集上快速查询，建立向量索引与标量索引，在联合查询场景下维护两套索引，若选择不好的执行计划，查询时延会大幅上升，对DB带来较大压力。

技术挑战

1. 端侧数据库考虑资源功耗问题没有统计信息，无法通过代价计算选择生成执行计划。
2. 构建轻量级混合索引，低底噪、低功耗、低时延查询。

当前结果



技术诉求

实现低功耗稳定低时延的向量标量联合查询。

1. 客观效率方面：百万128维向量与标量数据集下标量条件等值或者范围查询联合向量近似查询中，标量条件命中数量多少不影响时延召回率，10@10召回率>98%；
2. 主观感受方面：在对表中数据查询，对查询条件包含标量等值或这个范围查询并包含向量近似查询召回率与性能稳定，不会由于数据分布的问题导致部分查询出现劣化。

分解目标

动态增量混合索引：端侧数据是会不断增加更新，索引应可以从0数据量开始构建，增量更新数据不影响召回率。



情景举例：在端侧用户创建表和索引构建后用户插入大量数据，查询数据满足标量条件以及最近似的查询向量top10，低延时稳定查出结果。

考量点：(1)数据不断增删改，查询10@10召回率稳定>98%；(2)索引能够支持标量等值与范围查询，联合向量近似查询时延<10ms；(3)页缓存内存限制10M左右；(4)索引膨胀率不能高于原始向量1倍。(5)基于mate60进行验证。



OpenAtom OpenHarmony

需求点	状态	备注
动态增量混合索引	完成	10k 以内走纯内存精确近邻搜索, 超过阈值后落盘为磁盘图。
查询 10@10 召回率稳定 >98%	完成	v100 v3 selected 200/200 通过; 最小 recall@10 为 98.01%。
标量等值与范围查询	完成	
联合向量近似查询时延 <10ms	完成	v100 v3 packed serving 下 200/200 selected 点 avg/p95 latency 均 <10ms; p95 最大 9.56ms。
内存限制 30M 左右	完成	
索引总 footprint 低于原始向量 2 倍	完成	严格总 serving/raw 为 1.981x; 严格额外空间/raw 为 0.981x。

根据过滤选择性阈值 τ_m ，在同一个磁盘图索引上选择 prefilter 或 inline-processing ANNS。



标定曲线示意



曲线含义

- 先过滤随候选增多而变慢。
- 图搜索随有效点变密而变快。
- τ_m 为两路延迟的切换点。


标定方式

- 采样选择性点，测 recall@10 ≥ 98 下的两路延迟。
- 取延迟相近处写入 τ_m 。
- 标定期间暂停插入/删除。

16 线程依据

- v3 packed serving 下保留 4KB 随机读粒度。
- 7 个高风险慢点定向替换后，avg/p95 全部 $< 10\text{ms}$ 。


标签预处理手段



按标签选择性选择表示：小集合用 posting list 省空间，大集合用 bitmap 保持稳定求交速度。

标签表示

- 原始标签采用 spmat 格式：行是向量、列是标签，非零表示持有该标签。
- 预处理后生成混合标签结构：按标签候选规模选择 posting list 或 bitmap。
- posting list: `std::vector<uint32_t>`，保存向量 id。
- bitmap: `std::vector<uint64_t>`，每个 bit 表示一个向量。



实验结果

- SIFT1M/r116 原始 spmat 标签文件为 30.24 MiB。
- 构建后的混合标签 sidecar 为 0.89 MiB，约为原始 spmat 的 2.94%。
- v3 主磁盘图元数据中 `label_size=0`，标签不进入主 index record。


结论：混合标签预处理在保持标签语义的同时，带来明确的磁盘空间收益。

需求 0：从 0 插入与阈值前搜索

从 0 数据量向索引中插入向量时，进入纯内存模式；0–10k 向量直接插入内存数组，并执行精确近邻搜索。该阶段不训练 PQ、不生成磁盘图；索引中向量数超过 10k 后，再一次性落盘为磁盘图索引。

SIFT1M 前 10k 向量实验中，10k 以内全部保持纯内存模式；单查询峰值 RSS 最高约 **32.3 MiB**，接近 30MB 要求；平均搜索延迟最高约 **0.20 ms**，显著低于 10ms 延迟要求，10k 附近 QPS 约 **5k**。

结论：已支持从 0 数据量开始插入；落盘前延迟满足要求，内存占用与 30MB 目标基本一致。





需求 1: 召回率对比

左图：5 轮 delete/insert 后的 v3 selected 质量。允许重新选择 route/L 后，retrain 与 no-retrain 两类路径在每轮均保持 $\text{recall}@10 \geq 98$ ，且每轮最慢 avg/p95 latency $< 10\text{ms}$ 。

右图：全部 200 个 selected 点。新存储格式下，所有选择性、intersect/range、5 轮更新后的 selected 点均满足 $\text{recall}@10 \geq 98$ 且 avg/p95 latency $< 10\text{ms}$ 。


结论：按验收口径重新选择 route/L 后，v100 v3 packed serving 下 200/200 点通过 recall、avg latency 与 p95 latency 门槛。



需求 2：插入期间前台查询

在初始 1M 索引上插入向量的同时执行前台搜索，测量搜索延迟与 QPS，结果如下图。


结论：在插入线程数不大于 4 时，搜索时并发执行插入对搜索延迟的影响较小。




需求 3：全选择性查询延迟/QPS

1M 索引；等值 / 范围查询；PQ code 常驻内存；图中为 v3 packed serving 下满足 $\text{recall}@10 \geq 98\%$ 的 selected route/L。

结论：200 个动态 selected 点全部满足 $\text{recall}@10 \geq 98$ ；最大 avg latency 为 9.18ms，最大 p95 latency 为 9.56ms。



需求 4：查询进程峰值内存占用



测量方法

使用 `/usr/bin/time` 记录搜索进程峰值 RSS，查询文件和真值文件的内存占用不计入。


实测结果


PQ chunk=16 + PQ code 常驻内存时，所有选择性下的内存占用都在 30MB 左右。

需求 5：索引空间组成


v3 Supersector32K page-aware packing 保持 $R=116$ ，不把 4KB 随机读扩大到 32KB；主 index record 不存标签，标签位图作为 sidecar 计入 serving footprint。

严格口径下，1M serving 总 footprint / 原始向量为 **1.981x**，低于 2x；额外空间 / 原始向量为 **0.981x**，低于 1x。





PQ drift 策略比较 100/100 matched; cycle5 range-u30
使用 no-retrain L250 后 recall@10 = 98.55, 高于
matched target 98.27。



1 核后台 full build/PQ retrain 并发时, 前台 200/200
selected 点仍通过 10ms; during max avg/p95 =
9.25/9.54ms。

指标	v3 结果	备注
动态 selected recall@10	最小 98.01	允许重新选择 route/L 的验收口径，200/200 通过。
动态 selected avg latency	最大 9.18ms	200/200 点 <10ms。
动态 selected p95 latency	最大 9.56ms	200/200 点 <10ms。
PQ drift matched-reference	100/100	cycle5 range-u30 no-retrain L250 matched。
索引空间严格 total/raw	1.981x	严格额外/raw 为 0.981x。
后台维护干扰	9.25/9.54ms	1 核 full build/PQ retrain 并发时 avg/p95 通过。
读取粒度	4KB	straddling slot 使用两个 4KB 请求。

THE END

谢谢

