

廈門大學

本科毕业答辩



PipeANN 动态更新实验汇报

答辩人：林正刚

指导教师：沈志荣教授

需求 1: 召回率对比



固定 $L = 100$ 。左图比较直接构建、10k/250k/500k seed 增量插入的阶段召回；右图比较原始、删除、重插后的高选择性 graph-search 召回。



需求 2：插入期间前台查询




BIGANN/SIFT 前 2M；无插入为 1M initial，插入曲线为从 1M initial 后台插入到 2M。
每个选择性重新从干净 1M initial 开始，route/L 校准到 $\text{recall}@10 \geq 98$ 。圆点表示 $L = 10/\text{prefilter}$ ，三角表示 $L > 10/\text{graph}$ 。

Exp3: foreground search during insertion




需求 3: 选择性查询延迟/QPS

PQ32 + route/L 校准后, 30 个选择性点 recall@10 均不低于 98; 高选择性 graph 点中, 删除/重插后仍有少量平均延迟接近或略超 10ms。



三个状态分别对应: 原始 1M、删除到 750k、重插回 1M。图中延迟/QPS 均是在满足 recall@10 ≥ 98 后测得。

需求 4：单查询 RSS



结论：满足 30MB 限制。

口径：干净单查询进程总内存；
query vector 和过滤 label 通过命令
行传入，不加载 query file、
groundtruth 或 query spat。

30 个 RSS 点峰值为 **22.26 MiB**。

范围：1M initial 为 12.52–17.75
MiB；750k delete 为 15.22–20.60
MiB；1M reinsert 为 16.80–22.26
MiB。

重插 1M 更高，主要因为非 identity
tags 会加载 dense tag table；初始
1M 走 equal mapping。

原始向量空间按 $\text{npoints} * 128 * 4$ 计算; 额外索引空间均满足 $\text{extra/raw} \leq 1.0$ 。

- 250k: raw 122.07 MiB; 其他文件合计 252.20 MiB, 其中 disk.index 244.14 MiB, PQ compressed 7.63 MiB, PQ pivots 0.13 MiB, labels.densebit 0.30 MiB。
- 500k: raw 244.14 MiB; 其他文件合计 504.27 MiB, 其中 disk.index 488.29 MiB, PQ compressed 15.26 MiB, PQ pivots 0.13 MiB, labels.densebit 0.60 MiB。
- 750k: raw 366.21 MiB; 其他文件合计 756.34 MiB, 其中 disk.index 732.43 MiB, PQ compressed 22.89 MiB, PQ pivots 0.13 MiB, labels.densebit 0.89 MiB。
- 1M: raw 488.28 MiB; 其他文件合计 1008.41 MiB, 其中 disk.index 976.57 MiB, PQ compressed 30.52 MiB, PQ pivots 0.13 MiB, labels.densebit 1.19 MiB。

THE END

谢谢

